

Práctica 3: Extracción de Totales en Facturas mediante OCR y Machine Learning



Universidad
Rey Juan Carlos

| Campus de Móstoles

Autores:

Diego Esclarín (51729611N)

Sofía Contreras (09848471D)

Aplicaciones de Inteligencia Artificial
Grado en Ingeniería en Inteligencia Artificial
Universidad Rey Juan Carlos
Curso 2025–26

Índice

1. Introducción	5
2. Contexto	7
3. Estado del arte	9
4. Propuesta de solución	11
4.1. Fase 1: Comparativa de modelos de extracción	11
4.2. Fase 2: Pipeline móvil híbrido	12
4.3. Fase 3: Cambio de OCR — PaddleOCR vs EasyOCR	13
4.4. Pipeline final de producción	13
5. Conclusiones	15

Índice de figuras

1.	Comparativa general de los 8 modelos evaluados con EasyOCR: Exact Match, Match $\pm 5\%$ y MRE	11
2.	Impacto del preprocesamiento de texto OCR por modelo: la corrección de errores mejora todos los modelos entre 4 y 8 puntos porcentuales	12
3.	Baseline (número tras “total”) vs Gradient Boosting usado como método principal: GB supera al baseline en todas las métricas	12
4.	Comparativa PaddleOCR vs EasyOCR sobre CORD test: PaddleOCR es 18,8× más rápido y aporta +30 pp en Exact Match	13

1. Introducción

El objetivo de este proyecto es el desarrollo de un sistema inteligente capaz de extraer automáticamente el importe total de una factura o recibo a partir de su imagen. En un contexto donde la digitalización de documentos financieros avanza a gran velocidad, la capacidad de interpretar automáticamente estos documentos se convierte en una necesidad técnica para automatizar procesos contables, de auditoría y de gestión empresarial. El sistema propuesto actúa como un puente entre la imagen sin estructura que captura un dispositivo y el dato numérico preciso que necesita un sistema de gestión.

El núcleo de la investigación se centra en la combinación de dos tecnologías complementarias: el reconocimiento óptico de caracteres (OCR), que convierte la imagen en texto, y un modelo de aprendizaje automático que, a partir del texto extraído, identifica y selecciona el candidato numérico que corresponde al total de la factura. A diferencia de los enfoques basados exclusivamente en expresiones regulares o búsqueda de palabras clave, que fallan ante la variabilidad de formatos y los errores inherentes al OCR, el sistema emplea un clasificador Gradient Boosting entrenado sobre un conjunto de características diseñadas para capturar el contexto posicional y semántico de cada candidato numérico.

Finalmente, el proyecto destaca por su orientación a la eficiencia y el despliegue en dispositivos con recursos limitados. A lo largo de la experimentación se han evaluado ocho modelos de extracción y dos motores OCR, priorizando no solo la precisión, sino también el tiempo de inferencia y el tamaño del modelo resultante. El pipeline final, basado en PaddleOCR y Gradient Boosting, alcanza un 83,2 % de coincidencia exacta con un tiempo de procesamiento inferior a un segundo por imagen, lo que lo convierte en una solución viable para aplicaciones móviles y en tiempo real.

2. Contexto

El problema abordado es la extracción automática del importe total de facturas y recibos a partir de sus imágenes. Este proceso, que un humano realiza de forma casi instantánea, resulta complejo para un sistema automático debido a la enorme variabilidad en los formatos de los documentos: diferentes idiomas, divisas, disposiciones del texto, presencia de subtotales, impuestos, descuentos y otros importes que pueden confundirse con el total real.

El flujo de trabajo se divide en dos etapas fundamentales. La primera es el reconocimiento óptico de caracteres (OCR), que convierte los píxeles de la imagen en texto. Este paso introduce errores de lectura frecuentes: el carácter 0 se confunde con O, la 1 minúscula con el 1, o la D con el 0. La segunda etapa es la extracción del total a partir del texto obtenido, donde el sistema debe identificar cuál de los múltiples números presentes corresponde al importe total.

Los datos utilizados provienen del dataset CORD v2 [1], un corpus público de recibos de restaurantes coreanos e indonesios proporcionado por Naver-Clova a través de HuggingFace. El dataset contiene aproximadamente 800 muestras de entrenamiento y 100 de test y 100 de validación, cada una con la imagen del recibo y la anotación del total real (*ground truth*).

Para evaluar la eficacia de la extracción se utilizan las siguientes métricas:

- **Exact Match:** Porcentaje de facturas donde el total extraído coincide exactamente con el valor real.
- **Match $\pm 5\%$ y $\pm 10\%$:** Porcentaje de aciertos permitiendo un margen de error relativo del 5 % y 10 % respectivamente, útil para evaluar la tolerancia ante pequeños errores de OCR.
- **Prediction Rate:** Porcentaje de facturas para las que el sistema es capaz de devolver una predicción (cobertura).
- **MRE (Mean Relative Error):** Error relativo medio entre el valor predicho y el valor real.

El objetivo es transformar una imagen de factura en un dato numérico preciso, de forma eficiente y con un modelo lo suficientemente ligero para su despliegue en dispositivos móviles.

3. Estado del arte

La extracción de información estructurada a partir de documentos ha evolucionado significativamente en los últimos años, impulsada por los avances en OCR y en modelos de comprensión de documentos.

- **Reconocimiento óptico de caracteres (OCR):** Los motores OCR modernos como EasyOCR y PaddleOCR han democratizado el acceso a la digitalización de documentos. Mientras que EasyOCR ofrece soporte multilingüe y facilidad de uso, PaddleOCR destaca por su velocidad y precisión en la detección y reconocimiento de texto en escenarios variados [2]. La elección del motor OCR tiene un impacto directo en la calidad del texto extraído y, por tanto, en la precisión de la extracción posterior.
- **Extracción de campos en facturas:** Los enfoques clásicos se basan en expresiones regulares y búsqueda de palabras clave (*keyword matching*), que funcionan bien en formatos estandarizados pero fallan ante la heterogeneidad del mundo real. Trabajos recientes proponen modelos de aprendizaje automático que clasifican candidatos numéricos en función de su contexto textual y posicional [3], [4].
- **Modelos de comprensión de documentos:** Arquitecturas como LayoutLM [5] combinan información textual, visual y de disposición espacial para comprender documentos de forma integral. Sin embargo, estos modelos requieren recursos computacionales significativos (cientos de MB de almacenamiento y GPU para inferencia), lo que limita su aplicabilidad en dispositivos con recursos restringidos.
- **Modelos generativos (Seq2Seq):** Modelos como T5 pueden generar directamente el total a partir del texto OCR, alcanzando buena precisión. No obstante, su tamaño (~ 900 MB) y tiempo de inferencia (~ 14 s por imagen en CPU) los hacen inviables para aplicaciones en tiempo real o móviles.
- **Modelos clásicos de ML:** Algoritmos como Gradient Boosting, Random Forest y SVM ofrecen un equilibrio óptimo entre precisión y eficiencia. Cuando se combinan con un conjunto de características bien diseñado (*feature engineering*), estos modelos pueden igualar o superar a arquitecturas más complejas en tareas de clasificación de candidatos, con tiempos de inferencia de milisegundos y tamaños de modelo de pocos megabytes [4].

4. Propuesta de solución

Para abordar la extracción automática del total en facturas, se ha desarrollado un pipeline modular que combina OCR, preprocesamiento de texto y un clasificador de candidatos numéricos. El desarrollo se ha organizado en tres fases experimentales sucesivas, cada una construyendo sobre los hallazgos de la anterior.

4.1. Fase 1: Comparativa de modelos de extracción

Se implementaron y evaluaron ocho modelos de extracción sobre los mismos datos de entrenamiento (779 muestras CORD) y test (95 muestras):

- **Basados en reglas:** Regex Keyword (busca “total” + número adyacente) y Regex Max Filtrado (mayor número filtrando contextos negativos).
- **ML clásico:** Candidate Random Forest, Candidate Gradient Boosting y Candidate SVM, que clasifican candidatos numéricos mediante 12 características (posición relativa, magnitud, proximidad a keywords, contexto positivo/negativo, etc.).
- **NLP clásico:** TF-IDF + Logistic Regression con 3000 features y 1-2 gramas.
- **Deep Learning:** DistilBERT Reranker (clasificador binario fine-tuned) y T5 Seq2Seq (generación directa del total).




Figura 1: Comparativa general de los 8 modelos evaluados con EasyOCR: Exact Match, Match $\pm 5\%$ y MRE

Como se observa en la Figura 1, T5 obtuvo la mayor precisión (66,3 % Exact Match) pero con un coste inviable para móvil: 900 MB y 14 s por predicción. DistilBERT no justificó sus 250 MB al igualar a Random Forest. **Gradient Boosting** ofreció el mejor equilibrio calidad/coste: 52,6 % Exact Match, 0,18 s de predicción y ~ 2 MB de modelo.

Un hallazgo clave fue que todos los modelos alcanzan el 100 % de precisión con texto limpio (*ground truth*), demostrando que el cuello de botella es la calidad del OCR, no el modelo de extracción.




Figura 2: Impacto del preprocesamiento de texto OCR por modelo: la corrección de errores mejora todos los modelos entre 4 y 8 puntos porcentuales

El preprocesamiento de texto OCR (Figura 2) demostró mejorar consistentemente todos los modelos entre 4 y 8 puntos porcentuales. Este paso corrige errores típicos del OCR: $0 \rightarrow 0$, $1 \rightarrow 1$, $D \rightarrow 0$ cuando están adyacentes a dígitos, además de eliminar caracteres basura y normalizar espacios.

4.2. Fase 2: Pipeline móvil híbrido

Se propuso un pipeline de dos pasos para dispositivos móviles: primero Regex Keyword (0,01 ms) y, si falla, Gradient Boosting como fallback (2 ms).




Figura 3: Baseline (número tras “total”) vs Gradient Boosting usado como método principal: GB supera al baseline en todas las métricas

Sin embargo, Regex siempre devuelve un resultado (tiene fallback al número máximo), por lo que GB nunca se ejecutaba como fallback. La comparativa directa (Figura 3) confirmó que GB supera al baseline en +14,7 pp de Exact Match. **Decisión:** usar Gradient Boosting como método principal, no como fallback.

4.3. Fase 3: Cambio de OCR — PaddleOCR vs EasyOCR

El análisis de tiempos reveló que el 99,95 % del tiempo se consumía en el OCR ($\sim 4,7$ s con EasyOCR). Se evaluó PaddleOCR como alternativa.




Figura 4: Comparativa PaddleOCR vs EasyOCR sobre CORD test: PaddleOCR es $18,8\times$ más rápido y aporta +30 pp en Exact Match

Como muestra la Figura 4, PaddleOCR resultó ser **$18,8\times$ más rápido** (875 ms vs 16.417 ms por imagen) y produjo texto de mucha mejor calidad, lo que se tradujo en +30 puntos porcentuales de Exact Match. PaddleOCR v2.8.1 con PaddlePaddle 2.6.2 fue la combinación estable utilizada, requiriendo Python 3.12.

4.4. Pipeline final de producción

El pipeline final integra los hallazgos de las tres fases:

1. **PaddleOCR v2.8** — Detección y reconocimiento de texto sobre la imagen (~ 875 ms).
2. **Preprocesamiento de texto** — Corrección de errores típicos de OCR ($\sim 0,2$ ms).
3. **Extracción de candidatos** — Identificación de todos los números en el texto mediante expresiones regulares.
4. **Feature engineering** — Cálculo de 12 características por candidato: posición relativa en el documento, magnitud del número, proximidad a palabras clave (*total*, *amount*), contexto positivo y negativo, entre otras.
5. **Gradient Boosting** — Clasificador con 150 árboles y profundidad 5 que puntúa cada candidato y selecciona el de mayor probabilidad (~ 2 ms).

Las métricas finales del pipeline se recogen en la Tabla 1. El sistema alcanza un 83,2 % de coincidencia exacta con una cobertura del 100 % y un tiempo de procesamiento inferior a un segundo por imagen.

El sistema ofrece tres modos de uso: imagen individual (`--image`), procesamiento por lotes de un directorio (`--dir`) y captura en vivo con la cámara del dispositivo (`--camera`).

Cuadro 1: Métricas finales del pipeline PaddleOCR + Gradient Boosting sobre 95 muestras de test CORD

Métrica	Valor
Exact Match	83,2 %
Match ± 5 %	86,3 %
Match ± 10 %	88,4 %
Prediction Rate	100 %
MRE	0,12
Tiempo total/imagen	~ 877 ms
Tamaño modelo GB	~ 2 MB
Tamaño total pipeline	~ 350 MB

5. Conclusiones

El desarrollo de este sistema demuestra que la combinación de un motor OCR de alta calidad con un modelo clásico de aprendizaje automático bien diseñado constituye una solución altamente competitiva para la extracción de información estructurada en documentos financieros.

La experimentación en tres fases ha permitido extraer conclusiones fundamentales. En primer lugar, la comparativa de ocho modelos de extracción confirmó que **el cuello de botella reside en la calidad del OCR**, no en el modelo de extracción: todos los modelos alcanzan el 100 % de precisión con texto limpio. En segundo lugar, el preprocesamiento de errores OCR mejora consistentemente todos los modelos entre 4 y 8 puntos porcentuales, lo que justifica su inclusión permanente en el pipeline. En tercer lugar, la selección de PaddleOCR sobre EasyOCR supuso un salto cualitativo de +30 puntos porcentuales en precisión y una reducción de $18,8\times$ en tiempo de procesamiento.

El pipeline final, basado en PaddleOCR y Gradient Boosting, alcanza un 83,2% de Exact Match con un tiempo de inferencia inferior a un segundo y un modelo de solo 2 MB. Estas características lo hacen viable para su despliegue en dispositivos móviles y aplicaciones en tiempo real, a diferencia de alternativas como T5 (900 MB, 14 s) o DistilBERT (250 MB), que no justifican su coste computacional frente a la ganancia en precisión.

Como líneas futuras de trabajo se proponen:

- **Ampliación del dataset de entrenamiento:** Incorporar facturas de diferentes dominios (hoteles, comercios, servicios) y con mayor variedad de idiomas y divisas para mejorar la generalización del modelo.
- **Extracción de campos adicionales:** Extender el pipeline para extraer otros campos relevantes como la fecha, el nombre del establecimiento o el desglose de IVA, reutilizando la arquitectura de candidatos con características específicas por campo.
- **Optimización del OCR:** Evaluar versiones más recientes de PaddleOCR y técnicas de preprocesamiento de imagen (binarización adaptativa, corrección de perspectiva) para reducir aún más los errores de lectura.
- **Despliegue móvil nativo:** Exportar el modelo de Gradient Boosting a formato ONNX o CoreML para su integración directa en aplicaciones iOS y Android sin dependencia de Python.

Referencias Bibliográficas

- [1] S. Avidan, G. Brostow, M. Cissé, G. M. Farinella y T. Hassner, *Computer Vision–ECCV 2022: 17th European Conference, Tel Aviv, Israel, October 23–27, 2022, Proceedings, Part XX*. Springer Nature, 2022, vol. 13680.
- [2] V. Kumar, P. Kaware, P. Singh, R. Sonkusare y S. Kumar, «Extraction of information from bill receipts using optical character recognition,» en *2020 international conference on smart electronics and communication (ICOSEC)*, IEEE, 2020, págs. 72-77.
- [3] E. GUNAYDIN, B. GENCTURK, C. ERGEN y M. KÖKLÜ, «Digitization and Archiving of Company Invoices using Deep Learning and Text Recognition-Processing Techniques,» *Intelligent Methods In Engineering Sciences*, vol. 2, n.º 4, págs. 90-101, 2023.
- [4] T. Saout, F. Lardeux y F. Saubion, «An overview of data extraction from invoices,» *IEEE Access*, vol. 12, págs. 19 872-19 886, 2024.
- [5] Y. Xu, M. Li, L. Cui, S. Huang, F. Wei y M. Zhou, «Layoutlm: Pre-training of text and layout for document image understanding,» en *Proceedings of the 26th ACM SIGKDD international conference on knowledge discovery & data mining*, 2020, págs. 1192-1200.